

Proposal Proyek
Data Warehouse
S1 Sains Data, Fakultas Matematika dan Ilmu Pengetahuan Alam
Universitas Negeri Surabaya

Kelas : 2024 D
Ketua : Amelia Salsabila Ar rofik (24031554128)
Anggota 1 : Diva Izza Mansyanthika (24031554217)
Anggota 2 : Savitri Rahmaning Lukito (2403155219)
URL Github : [diabetes-datawarehouse-olap/README.md](https://github.com/Ameliasalsa/diabetes-datawarehouse-olap/README.md) at [main](#) .
[Ameliasalsa/diabetes-datawarehouse-olap](https://github.com/Ameliasalsa/diabetes-datawarehouse-olap)

Informasi Umum Proyek

Judul : Implementasi Data Warehouse untuk Analisis Faktor Risiko Diabetes dan Indikator Kesehatan Masyarakat Berbasis OLAP (2021-2026)

Topik : Sosial

BAB 1 PENDAHULUAN

1.1. Latar Belakang dan Deskripsi Rumusan Masalah

Diabetes Melitus merupakan salah satu penyakit kronis yang menjadi ancaman kesehatan masyarakat terbesar di dunia dengan jumlah penderita yang terus meningkat setiap tahunnya. Penyakit ini terjadi ketika tubuh mengalami gangguan dalam mengatur kadar glukosa darah sehingga dapat menyebabkan berbagai komplikasi serius, seperti penyakit jantung, gangguan ginjal, penurunan fungsi penglihatan, hingga menurunnya kualitas hidup penderita. Selain memberikan dampak terhadap kesehatan individu, Diabetes Melitus juga menimbulkan beban ekonomi yang besar bagi sistem pelayanan kesehatan dan produktivitas masyarakat. Upaya pencegahan serta deteksi dini Diabetes Melitus tidak dapat hanya mengandalkan intervensi medis, tetapi juga membutuhkan pendekatan berbasis data untuk memahami keterkaitan berbagai faktor risiko yang mempengaruhi kemungkinan seseorang mengalami diabetes. Faktor-faktor seperti usia (*age*), jenis kelamin (*gender*), indeks massa tubuh (*Body Mass Index/BMI*), hipertensi (*hypertension*), penyakit jantung (*heart disease*), riwayat merokok (*smoking history*), kadar HbA1c (*HbA1c level*), serta kadar glukosa darah (*blood glucose level*) memiliki hubungan yang penting dalam analisis risiko Diabetes Melitus.

Perkembangan teknologi informasi di bidang kesehatan menghasilkan data medis dalam jumlah besar yang terus bertambah dari waktu ke waktu. Namun, data kesehatan sering kali tersimpan dalam berbagai format dan struktur yang berbeda sehingga menyulitkan proses analisis secara terintegrasi. Sistem pengelolaan data yang masih bersifat transaksional (*Online Transaction Processing/OLTP*) umumnya hanya berfokus pada penyimpanan operasional dan belum optimal dalam mendukung kebutuhan analisis multidimensi maupun eksplorasi hubungan antar faktor risiko penyakit. Untuk mengatasi permasalahan tersebut, diperlukan pembangunan arsitektur *Data Warehouse* berbasis *Online Analytical Processing (OLAP)* yang mampu mengintegrasikan data kesehatan, melakukan proses transformasi data secara terstruktur, serta menyediakan fasilitas analisis multidimensi secara lebih efisien. Implementasi *Data Warehouse* memungkinkan proses agregasi data kesehatan dalam jumlah besar sehingga analisis faktor risiko Diabetes Melitus dapat dilakukan secara lebih sistematis, cepat, dan mendukung pengambilan keputusan berbasis data. Berdasarkan kondisi tersebut, terdapat beberapa tantangan teknis utama dalam pembangunan sistem *Data Warehouse* berbasis OLAP untuk analisis faktor risiko Diabetes Melitus, yaitu:

1. Integrasi Data Beragam Format

Mengintegrasikan data kesehatan yang memiliki berbagai atribut medis dan demografis ke dalam struktur data yang konsisten, valid, dan siap dianalisis.

2. Periodic Data Processing

Mensimulasikan proses ekstraksi data secara berkala untuk memenuhi kebutuhan *time granularity* pada Data Warehouse berbasis OLAP.

3. Transformasi dan Standarisasi Data

Melakukan proses pembersihan data, standarisasi format atribut, validasi kualitas data, serta normalisasi sebelum data dimasukkan ke Data Warehouse.

4. Optimasi Performa Query OLAP

Mengoptimalkan proses analisis multidimensi menggunakan fitur PostgreSQL seperti *Partition, Index, Materialized View*, serta implementasi *Cube Query*.

1.2. Target Insight yang Ingin Dicapai

Melalui proses Data Staging dan Data Presentation berbasis OLAP, proyek ini bertujuan memperoleh beberapa insight utama sebagai berikut:

1. Mengidentifikasi faktor kesehatan yang paling berpengaruh terhadap risiko Diabetes Mellitus.
2. Menganalisis hubungan BMI, hipertensi, penyakit jantung, dan riwayat merokok terhadap status diabetes.
3. Menganalisis distribusi risiko diabetes berdasarkan kelompok usia dan jenis kelamin.
4. Mengidentifikasi hubungan kadar HbA1c dan kadar glukosa darah terhadap kemungkinan seseorang mengalami diabetes.
5. Menyediakan visualisasi multidimensi menggunakan OLAP Cube untuk mendukung eksplorasi data kesehatan.

1.3. Referensi Penelitian

Penyusunan arsitektur *Data Warehouse* dan implementasi *Online Analytical Processing (OLAP)* dalam proyek ini didasarkan pada beberapa penelitian terdahulu berskala internasional yang menjadi landasan teoritis maupun praktis, khususnya dalam pengelolaan data kesehatan, integrasi data medis, analisis kesehatan berbasis *big data*, serta pemodelan multidimensi untuk penyakit kronis seperti Diabetes Mellitus. Secara spesifik, integrasi sistem dan pemodelan data dalam laporan ini mengacu pada literatur berikut:

1. **Perancangan Basis Data Klinis Diabetes:** Landasan mengenai metodologi perancangan *data warehouse* khusus untuk kebutuhan prediksi serta analisis klinis diabetes diadopsi dari penelitian pada jurnal *Computer Methods and Programs in Biomedicine* (2020) yang dapat diakses melalui tautan: *A Health Informatics Transformation Model Based on Intelligent Cloud Computing – Exemplified by Type 2 Diabetes Mellitus with Related Cardiovascular Diseases* – <https://www.sciencedirect.com/science/article/pii/S0169260720315517>
2. **Analisis Data Kesehatan Berbasis Big Data:** Untuk mendukung analisis indikator kesehatan masyarakat menggunakan pendekatan *big data analytics* pada data kesehatan berskala besar, proyek ini mereferensikan studi dari *Journal of Big Data* (2022) pada tautan: *The Use of Big Data Analytics in Healthcare* – <https://link.springer.com/article/10.1186/s40537-021-00553-4>
3. **Penyusunan Framework ETL:** Untuk penerapan alur kerja *Data Staging* yang meliputi proses *Extract, Transform, and Load (ETL)* serta pengembangan arsitektur analitik data kesehatan multi-dimensi, proyek ini mengacu pada penelitian yang dipublikasikan dalam *IEEE International Conference on Big Data* (2022) pada tautan: *Real-time Multi-granular Analytics Framework for HIT Systems* – <https://ieeexplore.ieee.org/document/10020539>

4. **Integrasi Representasi Data Penyakit Kronis:** Untuk integrasi representasi data kesehatan serta pemodelan hubungan kondisi penyakit kronis berbasis *Electronic Health Records (EHR)*, termasuk Diabetes Melitus Tipe 2, proyek ini mengadaptasi pendekatan dari penelitian pada *BioData Mining* (2022) pada tautan: *Learning and Visualizing Chronic Latent Representations Using Electronic Health Records* – <https://link.springer.com/article/10.1186/s13040-022-00303-z>

BAB 2 INFORMASI DETAIL DATASET

2.1. Sumber Dataset

Dataset yang digunakan dalam proyek ini merupakan **Diabetes Prediction Dataset**, yaitu kumpulan data medis dan demografis pasien yang digunakan untuk analisis faktor risiko Diabetes Melitus. Dataset memuat informasi kesehatan individu beserta status diabetes yang menunjukkan apakah seseorang terindikasi mengalami diabetes atau tidak. Proses akuisisi data dilakukan melalui platform publik penyedia dataset analisis kesehatan dalam format *Comma Separated Values (CSV)* sehingga dapat digunakan pada proses pembangunan *Data Warehouse*. Data diperoleh melalui proses pengunduhan (*data acquisition*) kemudian diproses menggunakan mekanisme *Extract, Transform, and Load (ETL)* sebelum dimasukkan ke repositori analitik berbasis PostgreSQL.

Pada tahap *Extract*, sistem melakukan pembacaan data CSV menggunakan *reader/parser* berbasis Python. Selanjutnya pada tahap *Transform*, dilakukan proses pembersihan data (*data cleaning*), validasi tipe data, standarisasi atribut, serta simulasi ekstraksi periodik untuk memenuhi kebutuhan *time granularity* pada implementasi *Online Analytical Processing (OLAP)*. Tahap *Load* dilakukan dengan memasukkan data hasil transformasi ke dalam sistem basis data PostgreSQL untuk kebutuhan analisis multidimensi. Dataset dipilih karena memiliki atribut medis yang relevan terhadap analisis faktor risiko Diabetes Melitus serta mendukung kebutuhan pembangunan sistem analitik kesehatan berbasis *Data Warehouse*. Variabel yang tersedia memungkinkan proses eksplorasi hubungan antar faktor kesehatan serta mendukung pembentukan struktur multidimensi untuk kebutuhan OLAP.

2.2. Deskripsi Umum Dataset

Dataset terdiri atas data medis dan data demografis pasien yang digunakan untuk analisis faktor risiko Diabetes Melitus. Variabel yang digunakan pada dataset ini meliputi:

Variabel	Deskripsi
Gender	Jenis Kelamin
Age	Usia Pasien
Hypertension	Riwayat Hipertensi
Heart Disease	Riwayat penyakit jantung
Smoking History	Riwayat Merokok
BMI	Body Mass Index
HbA1c Level	Kadar Hemoglobin A1c
Blood Glucose Level	Kadar Glukosa darah

Diabetes	Status diabetes pasien
----------	------------------------

Variabel target dalam dataset adalah Diabetes, yang digunakan untuk mengidentifikasi kondisi individu terhadap risiko Diabetes Melitus.

Kelas target terdiri atas:

- 0 = Tidak Diabetes
- 1 = Diabetes

Dataset ini digunakan untuk mendukung pembangunan *Data Warehouse* berbasis OLAP sehingga memungkinkan analisis multidimensi terhadap hubungan faktor kesehatan dan kondisi Diabetes Melitus.

2.3. Aspek Khusus Dataset

2.3.1. Sparsity Data

Sparsity merupakan kondisi ketika dataset memiliki banyak nilai kosong (missing value) atau atribut yang tidak terisi. Pemeriksaan *sparsity* dilakukan untuk mengetahui kualitas data sebelum memasuki tahapan *Extract, Transform, and Load (ETL)*.

Persentase *sparsity* dapat dihitung menggunakan rumus:

$$Sparsity = \frac{Jumlah\ Missing\ Value}{Total\ Data} \times 100\%$$

Dataset akan dilakukan pemeriksaan nilai kosong pada seluruh atribut seperti *Age*, *BMI*, *HbA1c Level*, *Blood Glucose Level*, serta variabel kesehatan lainnya untuk memastikan konsistensi data sebelum proses integrasi ke *Data Warehouse*.

2.3.2. Ketidakseimbangan Data (Class Imbalance)

Dataset dianalisis untuk mengetahui distribusi kelas pada variabel target Diabetes. Distribusi kelas yang tidak seimbang (imbalance dataset) dapat mempengaruhi proses analisis serta kualitas hasil eksplorasi data. Rasio ketidakseimbangan kelas dihitung menggunakan:

$$Ratio = \frac{Jumlah\ Data\ Kelas\ Mayoritas}{Jumlah\ Data\ Kelas\ Minoritas}$$

Analisis distribusi kelas dilakukan untuk mengetahui proporsi pasien diabetes dan non-diabetes sebelum proses analisis multidimensi dilakukan.

2.3.3. Outlier Data

Outlier Data dengan nilai ekstrem yang memiliki perbedaan signifikan dibanding sebagian besar data lainnya. Deteksi Outlier dilakukan pada atribut numerik meliputi:

- Age
- BMI
- HbA1c Level
- Blood Glucose Level

Proses identifikasi outlier dilakukan menggunakan beberapa metode, yaitu:

- Interquartile Range (IQR)
- Boxplot
- Histogram distribusi data

Tahapan ini bertujuan menjaga kualitas data sebelum dimasukkan ke sistem *Data Warehouse*.

2.3.4 Time Granularity

Karena dataset tidak memiliki atribut waktu historis secara langsung, proyek ini menerapkan simulasi *time granularity* untuk memenuhi kebutuhan implementasi OLAP. Simulasi dilakukan dengan

pembentukan atribut waktu (*timestamp simulation*) sehingga proses *periodic extraction* dapat dilakukan untuk mendukung analisis multidimensi.

2.4. Breakdown Implementasi ETL dan OLAP

Tahapan implementasi sistem Data warehouse dalam proyek ini terdiri atas beberapa komponen utama.

Komponen	Implementasi Proyek
Data Dump	Diabetes Prediction Dataset
Periodic	Simulasi Ekstraksi data periodik
Reader / Parser (Extract)	Python CSV Reader
Pre-processing (Transform)	Data cleaning, validasi atribut, standarisasi format, simulasi waktu
Feeder (Load)	PostgreSQL Cloud Database
Postgre SQL Extension	Materialized View, Partition, Index
DataMart	Atoti Cube
Widget / Visualisasi	Dashboard OLAP Atoti

2.5. Rancangan Proses ETL

Tahapan *Extract, Transform, and Load (ETL)* pada proyek dilakukan sebagai berikut:

Extract

Tahap *Extract* dilakukan dengan membaca dataset CSV menggunakan Python untuk memperoleh data mentah (*raw data*) dari sumber dataset.

Transform

Tahapan Transform mencakup:

- Pemeriksaan missing value
- Validasi tipe data
- Pembersihan data
- Standarisasi data
- Simulasi data periodik
- Identifikasi outlier
- Integrasi atribut multidimensi

Load

Tahap *Load* dilakukan dengan memasukkan data hasil transformasi ke PostgreSQL Cloud sebagai repositori utama *Data Warehouse* untuk mendukung proses analisis OLAP.

BAB 3 RENCANA DATA STAGING

3.1. Gambaran Umum Proses Ekstraksi

Tahap ekstraksi (Extract) merupakan proses pengambilan data mentah (*raw data*) dari sumber dataset utama untuk diproses lebih lanjut dalam sistem Data Warehouse. Pada proyek ini, sumber data yang digunakan adalah Diabetes Prediction Dataset. Proses ekstraksi dilakukan menggunakan

reader/parser berbasis Python untuk membaca data dari file CSV kemudian memindahkan data ke area *staging* sebelum dilakukan proses transformasi. Tahapan ini bertujuan memastikan data dapat diakses dan diproses secara konsisten sebelum dimasukkan ke sistem analitik. Untuk memenuhi kebutuhan implementasi *periodic processing* pada *Data Warehouse*, proses ekstraksi akan disimulasikan berlangsung secara berkala (*periodic extraction*) melalui pembentukan atribut waktu sehingga mendukung kebutuhan analisis berbasis *time granularity*.

Alur ekstraksi yang direncanakan:

1. Membaca dataset CSV menggunakan Python.
2. Melakukan validasi struktur data awal.
3. Memindahkan data ke staging area.
4. Menambahkan atribut waktu simulasi untuk kebutuhan ETL periodik.
5. Menyiapkan data untuk proses transformasi.

3.2. Gambaran Umum Proses Transformasi

Tahap transformasi (*Transform*) dilakukan untuk meningkatkan kualitas data sebelum dimasukkan ke dalam *Data Warehouse*. Proses ini bertujuan menghasilkan data yang bersih, konsisten, dan sesuai kebutuhan analisis multidimensi.

Beberapa kondisi aktual pada dataset yang membutuhkan transformasi meliputi:

1. Standarisasi Tipe Data

Variabel numerik seperti:

- AGE
- BMI
- HbA1c Level
- Blood Glucose Level

Perlu dilakukan validasi tipe data untuk memastikan seluruh atribut berada pada format yang sesuai.

Rasionalisasi: Mendukung aspek **integration** pada Data Warehouse agar data memiliki format yang seragam.

2. Pemeriksaan Missing Value

Pemeriksaan nilai kosong (*missing value*) dilakukan untuk menjaga kualitas data sebelum proses analisis.

Rasionalisasi: Mendukung aspek data quality dan konsisten data.

3. Identifikasi Outlier

Variabel numerik diperiksa menggunakan metode:

Interquartile Range (IQR)

Distribusi Histogram

Boxplot

Rasionalisasi: Mengurangi pengaruh nilai ekstrim yang dapat mempengaruhi proses analisis multidimensi.

4. Simulasi Time Granularity

Karena dataset tidak m

memiliki atribut waktu historis secara langsung, akan dilakukan simulasi atribut waktu (*timestamp*) untuk memenuhi kebutuhan OLAP.

Rasionalisasi: Mendukung aspek:

Time Variance

Periodic Processing

OLAP Time Dimension

5. Integrasi Data

Data hasil transformasi akan disusun dalam struktur multidimensi yang mendukung pembangunan Fact Table dan Dimension Table.

Rasionalisasi: Mendukung aspek:

Subject-Oriented

Integration

Multidimensional Analysis

3.3. Gambaran Umum Proses Load

Tahap Load merupakan proses memasukkan data hasil transformasi ke sistem penyimpanan utama Data Warehouse. Repository penyimpanan menggunakan PostgreSQL berbasis cloud untuk mendukung proses OLAP serta analisis multidimensi.

Workflow proses Load yang direncanakan:

1. Penyimpanan Data Raw
2. Penyimpanan Data Hasil Transformasi
3. Pembentukan Struktur Data Warehouse
4. Optimasi PostgreSQL
5. Pembuatan OLAP Cube
6. Visualisasi Data.

BAB 4 RENCANA DATA PRESENTATION

4.1. Subject Focus

Subject utama yang diangkat dalam proses OLAP adalah analisis faktor risiko Diabetes Melitus berdasarkan data medis dan demografis pasien. Proses OLAP difokuskan untuk mengeksplorasi hubungan antar atribut kesehatan yang berpotensi mempengaruhi kondisi diabetes, seperti usia, jenis kelamin, indeks massa tubuh (*Body Mass Index/BMI*), riwayat hipertensi, penyakit jantung, riwayat merokok, kadar HbA1c, serta kadar glukosa darah. Pendekatan multidimensi digunakan untuk memungkinkan analisis data berdasarkan berbagai sudut pandang (*multidimensional analysis*) sehingga pola hubungan faktor risiko Diabetes Melitus dapat diamati secara lebih mendalam.

Subject utama yang dianalisis meliputi:

1. Distribusi status diabetes berdasarkan kelompok usia.
2. Hubungan BMI terhadap status diabetes.
3. Analisis kadar HbA1c terhadap kondisi diabetes.
4. Pengaruh riwayat hipertensi dan penyakit jantung terhadap risiko diabetes.
5. Hubungan riwayat merokok terhadap status diabetes.
6. Distribusi diabetes berdasarkan karakteristik demografis.

4.2. Star Schema

Rancangan *Star Schema* digunakan untuk mendukung kebutuhan OLAP sehingga proses agregasi dan eksplorasi multidimensi dapat dilakukan dengan lebih efisien. Struktur *Star Schema* yang direncanakan terdiri atas satu *Fact Table* dan beberapa *Dimension Table*.

- Fact Table

- Fact_Diabetes

Measure yang digunakan:

- Total pasien
- Jumlah pasien diabetes
- Rata - rata BMI
- Rata - rata HbA1c
- Rata - rata Blood Glucose Level

- Foreign Key:

- Tim_ID
- Patient_ID
- Health_ID
- Smoking_ID

Fact table digunakan sebagai pusat analisis multidimensi karena menyimpan data numerik (*measures*) yang akan dilakukan agregasi pada proses OLAP.

- Dimension Table

-Dim_Patient

Atribut:

- Patient_Id
- Gender
- Age

Fungsinya untuk mendukung analisis karakteristik demografis pasien.

-Dim_Healt

Atribut:

- Health_ID
- BMI
- Hypertension
- Heart_Disease
- HbA1c_Level
- Blood_Glocose_Level

Fungsinya untuk mendukung analisis faktor kesehatan terhadap resiko Diabetes Melitus.

-Dim Smoking

Atribut:

- Smoking_ID
- Smoking_History

Fungsinya untuk mendukung eksplorasi hubungan perilaku merokok terhadap diabetes.

-Dim_Time

Atribut:

- Time_ID
- Tahun
- Bulan

Fungsinya untuk mendukung analisis time granularity pada OLAP

4.3. Target Hasil OLAP

Insight awal yang ingin dicapai melalui mekanisme OLAP meliputi:

1. Identifikasi Faktor Risiko Utama

Menentukan atribut kesehatan yang memiliki hubungan paling kuat terhadap kondisi Diabetes Melitus.

2. Analisis Demografis

Mengidentifikasi distribusi diabetes berdasarkan:

- Usia
- Jenis kelamin

3. Analisis Kesehatan Multidimensi

Mengamati hubungan:

- BMI terhadap diabetes.

- HbA1c terhadap diabetes.
 - Blood glucose terhadap diabetes.
 - Hipertensi terhadap diabetes
 - Penyakit jantung terhadap diabetes.
4. Analisis Time Dimension
Menganalisis pola perubahan data berdasarkan simulasi periode waktu untuk kebutuhan OLAP
 5. Dashboard Analitik
Menghasilkan visualisasi OLAP menggunakan Atoti sehingga proses eksplorasi data dapat dilakukan secara interaktif. Target akhir proyek adalah menghasilkan sistem *Data Warehouse* berbasis OLAP yang mampu memberikan insight faktor risiko Diabetes Melitus secara multidimensi serta mendukung analisis kesehatan berbasis data.